Présentation activité Crawl

Suzanne FELIX & Sabrina MESSALI

Sommaire

- Sujet
- Sites d'entrée
- Déroulé du Crawl
- Processus de nettoyage
- Consultation et paramétrage des résultats
- Analyse
- Difficultés
- Gephi



Sujet


Le sujet qui nous a été attribué est l'étude du réseau entre formations de l'université Paris 8 Vincennes Saint Denis et autorités dans le domaine des humanités numériques.



Sujet Définition des termes

Digital humanities (humanités numériques) :

« La rencontre entre les nouvelles technologies de l'information et de la communication et les disciplines des sciences humaines et sociales, des arts et des lettres. »



Les sites d'organisations utilisés en entrée

Le site du centre interuniversitaire sur les humanités numériques (CRIHN)

L'infrastructure de recherche IR
Huma Num

La fondation maisons des sciences

de l'homme

The European Association for Digital Humanities (EADH)
(Association européenne pour les humanités numériques)

The Alliance of Digital Humanities
Organizations (ADHO)

(Alliance des organisation d'humanités numériques)


Les sites des laboratoires de Paris 8 utilisés en entrée

UR Laboratoire Paragraphe

UR Laboratoire d'Intelligence Artificielle et Sémantique des Données (LIASD)

UR Centre d'études sur les médias, les technologies et l'internationalisation -CEMTI (Research Unit: Centre for Studies in Media, Technologies and Internationalisation)

UR Centre de recherches et d'analyses géopolitiques - IFG-LAB (Research Unit: Centre for Geopolitical Research and Analysis) Le Laboratoire des Usages en Technologies d'Information Numériques (LUTIN)




Le crawl

- Logiciel: Hyphe
- Médialab de Science Po
- Deux profondeurs de clics
- 3010 pages crawlés

Nettoyage


- Statut « out » :
- GAFAM: Google.com, Facebook, Amazon, Twitter
- Autres : Zoom, Zotéro, Viméo



✓ UNDECIDED □ OUT DISCOVERED DISCOVERED web entities only connected DISC

Consultation et paramétrage

- In / Undecided / Discorvered sélectionnés
- 2 exports des données
 - JSON
 - Markdown
- 3 exports du graphe
 - 1 lien
 - 2 liens
 - 3 liens
- · Consultation sur Github et Gephi




Consultation et paramétrage


- Observation avecles paramètres
- IN
- IN + DISCOVERED + « display only connected discovered »
- IN + DISCOVERED + « display only connected discovere with 2+ links »
- IN + DISCOVERED + « display only connected discovere with 3+ links »

Analyse : observations

- Observation de 6 clusters très denses
- Clusters les plus important : Paris 8 et <u>The European</u> Association for Digital Humanities
- Hubs: Paris 8 et <u>The European Association for Digital</u> <u>Humanities</u>
- Autoritées: infrastructure de recherche IR Huma Num, la fondation Maisons des sciences de l'homme, l'Alliance of digital humanities organizations et le site du centre interuniversitaire sur les humanités numériques (CRIHN).
- Laboratoires de Paris 8 isolés
- Pas ou peu d'autres liens autre qu'avec le noeud de Paris 8
- Pas d'interconnexion entre les nœuds des laboratoires
- Les petits clusters au milieu du graphe sont composés d'universités, de presse scientifique ou de portail de publication scientifique









Analyse :interpretation

- Densité des 6 clusters → forte cohesion d'un reseau autour d'une autorité
- Les nœuds se concentrent autour d'une seule organisation montrant un manque d'intérêt, de partenariat ou de cohésion avec les autres organisations du corpus d'entrées
- Les partenariats entre laboratoires de Paris 8 et d'autres universités permettent une valorisation de ces derniers
- Les laboratoires de Paris 8 sont isolées les uns des autres ce qui créer une perte de visibilité de ces derniers : des événements communs engendrer une meilleure cohésion de ce groupe
- Liées les laboratoires et les organisations faisant figure d'autorité dans le domaine des humanités numériques permettrait une meilleure visibilité et une meilleure cohésion des acteurs de ce domaine











Difficultés et questions


- Logiciel Gephi compliquée à prendre en main
- Problème avec Gephi sous windows 11 (non rencontré sous windows 10)
- · Pas de difficultés sur le crawl
- Revoir le nettoyage ?




Gephi



Gephi



Gephi





Merci pour votre attention. Des questions ?